

POLITECHNIKA ŚLĄSKA W GLIWICACH

OBLICZENIA RÓWNOLEGŁE II

Komunikacja między procesami oraz redukcja danych (MPI)

AUTOR:
Bartłomiej Buchała

Informatyka SSM, semestr II
Rok akademicki 2016/2017
Grupa OS1

27 listopada 2016

1 Wstęp

Wraz z rozwojem nauk ścisłych pojawiają się coraz bardziej skomplikowane problemy natury naukowej. Do ich rozwiązania niezbędne są komputery o dużej mocy obliczeniowej. Rozwój technologii pozwolił jednak na stworzenie maszyn o większej szybkości obliczeń. Zgodnie z prawem Moore'a, które zakłada, że liczba tranzystorów w procesorach rośnie wykładniczo, moc obliczeniowa jrdnostek centralnych wzrasta dwukrotnie co każde dwa lata. Przy stałym zwiększaniu taktowania procesora, napotkano jednak pewien problem – dla pewnego progu zużycie prądu (a przede wszystkim temperatura pracującego CPU) rosną eksponencjalnie w stosunku do częstotliwości taktowania. W okolicach 2005 roku, większość producentów procesorów zdecydowała się wykorzystać inne podejście – zastosować obliczenia równoległe. W tym celu, zamiast rozwijać coraz to szybsze (a konkretnie – wyżej taktowane) procesory monolityczne, kolejne jednostki centralne miały zostać wyposażone w wielokrotne procesory zintegrowane w jednym obwodzie – tak zwane **procesory wielordzeniowe**.

Dodanie dodatkowych rdzeniów nie rozwiązało jednak w magiczny sposób problemów z wydajnością w przypadku większości istniejących programów. Główną przyczyną był fakt, że spora część algorytmów przygotowana była z myślą o wykonaniu sekwencyjnym – czyli przeznaczonym do wykonaniu na jednym procesorze. W tym przypadku wykonywany kod nie był świadomy obecności innych jednostek obliczeniowych, co uniemożliwiało ich użycie przy wykonywaniu kolejnych rozkazów. Szybkość z jaką wykonywał się taki program była zazwyczaj zbliżona do tej wyliczonej w trakcie użycia jednego procesora. Do doprowadziło do powstania do programów równoległych.

Przez **programowanie równoległe** rozumiemy taką metodę tworzenia algorytmu, która pozwala jednoznacznie wskazać, które fragmenty obliczeń mają zostać wykonane w sposób równoległy na osobnych procesorach. W tym celu wyodrębniono 3 pojęcia:

Program współbieżny (ang. *concurrent*) występuje w przypadku, gdy procesy są wykonywane przez jeden procesor rzeczywisty metodą przepłotu.

Program równoległy (ang. *parallel*) to przypadek, kiedy każdy proces wykonywany jest przez osobną jednostkę obliczeniową, a procesory posiadają dostęp do wspólnej pamięci.

Program rozproszony (ang. *distributed*) występuje, gdy procesy wykonywane są przez odrębne, rozproszone procesory połączone kanałami komunikacyjnymi.

W pierwszym rozpatrywanym przypadku nie dochodzi do prawdziwego wykonania równoległego, ponieważ w dowolnym momencie czasu nie istnieją przynajmniej 2 procesy, które są wykonywane jednocześnie. Obliczeniami zajmuje się jeden procesor, a kolejne rozkazy procesorów wykonywane są na zmianę – pomiędzy nimi zachodzi przełączanie kontekstu (zapamiętanie niezbędnych danych dotyczących stanu procesu). W dwóch pozostałych scenariuszach, należy rozwiązać dodatkowo jeden problem: komunikację między procesorami w określonych momentach obliczeń. Istnieją dwa sposoby realizacji takiego przedsięwzięcia:


- Wykorzystanie **pamięci wspólnej** – zakłada ono istnienie pamięci operacyjnej, w której znajdują się dane potrzebne do obliczeń. Każdy procesor biorący udział w obliczeniach ma dostęp do zmiennych wspólnych (ang. *shared variables*), na których może wykonywać określone operacje (np. operacje czytania, zapisu, lub bardziej zaawansowane jak porównanie-zamiana lub czytanie-modyfikacja-zapis).
- Przesył wiadomości za pomocą **kanałów komunikacyjnych** – zakłada istnienie specjalnych kanałów, poprzez które procesory wysyłają między sobą wirtualne wiadomości. Każdy kanał jest dwukierunkowy i łączy 2 procesory, natomiast ich zbiór stanowi sieć połączeń. Procesory w klastrze mogą być połączone w różne schematy, np. listy cyklicznej czy macierzy. Obliczenia wykonywane są asynchronicznie, gdyż nie można dokładnie określić momentów, w których operacje wykonywane są współbieżnie, a także momentów wysyłu i odbioru wiadomości pomiędzy poszczególnymi CPU.

W latach 90-tych XX wieku powstały dwa standardy, które miały ułatwić tworzenie i pracę z kodem przeznaczonym do wykonania równoległego: OpenMP (ang. *Open Multi-Processing*), który charakteryzuje się wykorzystaniem pamięci wspólnej) oraz MPI (ang. *Message Passing Interface*), korzystający z kanałów komunikacyjnych. Dalsza część referatu zostanie poświęcona temu drugiemu.

2 Interfejs MPI

2.1 Model sieciowy

Komunikacja odbywa się za pomocą przesyłania wiadomości (czyli między innymi w standardzie MPI) w tak zwanym modelu sieciowym. Składa się on z określonej liczby procesorów, przy czym każdy z nich posiada własną pamięć lokalną. Procesory posiadają dostęp jedynie do instrukcji i danych przechowywanych w swojej pamięci lokalnej – nie istnieje pamięć wspólna. Aby umożliwić wymianę informacji pomiędzy procesorami, tworzona jest sieć połączeń (ang. *interconnection network*), która zbudowana jest z dwukierunkowych kanałów komunikacyjnych (łączy).



Rysunek 1: Model sieciowy. Źródło: [4], str 94


Wymiana informacji między procesorami jest realizowana poprzez kooperujące ze sobą procedury trasowania (ang. *routing*), które działają w każdym procesorze. Dzięki nim, każdy węzeł sieci (tutaj: procesor) posiada informację, z którymi węzłami może wymieniać informacje. Zbiór wszystkich procedur trasowania definiuje **topologię sieci połączeń**. Można ją opisać przy pomocy grafu, gdzie wierzchołkami (węzłami) są procesory, natomiast krawędzie to dwukierunkowe łącza.

Ocenę skuteczność/przydatność danej sieci podczas prowadzenia obliczeń równoległych można określić biorąc pod uwagę kilka parametrów:

- **Średnica sieci** (ang. *diameter*) – maksymalna odległość zmierzona za pomocą liczby krawędzi między dowolnymi dwoma wierzchołkami. Im mniejsza średnica, tym lepsza jest sieć – oznacza to, że informacje będą potrzebowały średnio mniej czasu na dotarcie do właściwego odbiorcy. Przypadek pesymistyczny zakłada, że wiadomość będzie musiała zostać przesłana przez liczbę krawędzi równej średnicy.
- **Szerokość połowienia sieci** (ang. *bisection width*) – minimalna liczba krawędzi, którą należy usunąć z obecnej sieci, aby móc ją podzielić na 2 równe podsieci.
- **Szerokość pasma** (ang. *bisection bandwidth*) – jest to iloczyn szerokości połowienia oraz szybkości przesyłu danych w pojedynczym kanale. Pozwala określić liczbę bitów, jaką można przesłać między półkami w jednostce czasu. Im większa szerokość pasma, tym lepiej.
- **Maksymalny stopień wierzchołka** – maksymalna liczba krawędzi połączonych z danym wierzchołkiem (liczona globalnie dla całej sieci). Dla niewielkiego stopnia łatwiej zaprogramować procedury komunikacyjne ze względu na fakt, że używają one mniejszej liczby kanałów. Zakłada się, że sieć jest dobra jeżeli przy wzroście liczby p procesorów średnica sieci rośnie nie szybciej niż logarytmicznie w funkcji p , natomiast maksymalny stopień wierzchołka jest stałą liczbą o małej wartości.
- **Spójność krawędziowa** (ang. *edge connectivity*) – definiowana jako minimalna liczba krawędzi, które muszą zostać wyłączone z sieci aby ta stała się niespójna (graf rozłoży się na 2 lub więcej osobnych podgrafów). Im większa spójność krawędziowa, tym odporniejsza jest sieć – istnieje mniejsze prawdopodobieństwo całkowitego unieruchomienia sieci w przypadku, gdy któryś procesor ulegnie uszkodzeniu. Większa spójność prowadzi też do zmniejszenia rywalizacji poszczególnych węzłów o łącze.
- **Koszt sieci** – zazwyczaj określana jako suma wszystkich kanałów w sieci.

Przykładowe topologie sieci połączeń:

- siatka
- torus (jedno-, wielowymiarowy)
- kostka (jedno-, wielowymiarowa)



Rysunek 2: Topologia kostki. Od lewej: jedno-, dwu- oraz trójwymiarowa. Źródło: [3], str 40

2.2 Zasada działania MPI

MPI jako interfejs przeznaczony do pracy z obliczeniami rozproszonymi oparty został o model sieciowy, posiadają jednak kilka cech, które wyróżniają od standardowej implementacji tego wzorca. MPI można potraktować jako interfejs pomiędzy programem a systemem operacyjnym.

Tradycyjnie, każdy z procesów posiada własną pamięć lokalną, co narzuca konieczność komunikacji przez dwukierunkowe łącza komunikacyjne (w nomenklaturze MPI nazywane **komunikatorami**). Komunikacja polega na przesłaniu danych z pamięci procesu źródłowego do pamięci lokalnej procesu docelowego przy wykorzystaniu węzłów pośrednich. Domyślnie każdy nowoutworzony proces znajduje się w komunikatorze świat (MPI_COMM_WORLD). Takie rozwiązanie sprawia, że każdy proces może wymieniać dane z dowolnym spośród pozostałych, niezależnie od fizycznej struktury procesorów (jest ona przezroczysta dla procesów). Istnieje możliwość zdefiniowania własnych komunikatorów – co może okazać się przydatne w przypadku, gdy programista chce zawęzić zakres procesów, do których wysyłana jest wiadomość rozgłoszeniowa (ang. *broadcast*).

W trakcie tworzenia programu w oparciu o ten interfejs, warto podzielić część programu przeznaczoną do obliczeń rozproszonych na części, które mają zostać przydzielone do osobnych procesów. Na początku pracy, deklarowana jest ilość procesów, które mają zostać zaangażowane do pracy. Może się to odbywać na jeden z 2 sposobów:

- Statyczny – procesy tworzone są przed wykonaniem programu. Program (proces główny, tak zwany *root*) nie może zostać zakończony przed końcem pracy wszystkich pozostałych procesów.
- Dynamiczny – Potrzebne procesy są tworzone podczas pracy programu. Ta opcja jest dostępna wyłącznie dla wersji MPI-2 (zaprezentowanej w 1997 roku).

Każdy utworzony proces posiada własny unikalny identyfikator (id) w ramach komunikatora. W różnych komunikatorach ten sam proces może posiadać różne id. Identyfikatorem procesu głównego (*roota*) jest liczba 0.

W momencie tworzenia nowego procesu, tworzona jest kopia programu przeznaczonego tylko dla tego procesu. W praktyce oznacza to, że posiada dostęp do każdej zmiennej zadeklarowanej globalnie, jednak tylko w ramach lokalnej kopii. W przypadku, gdy proces potrzebuje danych znajdujących się w innym węźle, konieczna jest wymiana informacji w ramach komunikatora. Do rozdzielania pracy stosuje się standardowe operacje rozgałęzienia (między innymi instrukcje *if* czy *else* w językach C/C++) identyfikując id procesu. Jest to technika zwana SPMD (*Single Program Multiple Data* – pojedynczy program, wiele danych), będący subkategorią MIMD (*Multiple Instruction Multiple Data* - wiele instrukcji, wiele danych), znanej z taksonomii Flynna. Zazwyczaj utworzone kopie programów działają w sposób asynchroniczny, lecz może dojść do sytuacji, w której procesy te będą działały synchronicznie. Określony sposób działania może być uzależniony od funkcji, jakie zostaną użyte przez programistę.

2.3 Kompilacja i uruchamianie

Szczegóły związane z kompilacją i uruchamianiem programu napisanego przy użyciu biblioteki MPI są zależne od używanego systemu operacyjnego. Większość z nich do kompilacji używa komendy, której można użyć z poziomu linii poleceń/terminala:

```
$ mpicc -g -Wall -o <plik_źródłowy> <plik_wynikowy>.c
```

Zazwyczaj `mpicc` jest skryptem opakującym (ang. *wrapper script*) dla kompilatora języka (dla powyższego przypadku, języka C). Skrypt opakowujący jest pisany w celu uruchomienia określonego programu. Skrypt ten upraszcza uruchomienie kompilatora poprzez jawne wskazanie, w którym miejscu znajdują się potrzebne pliki nagłówkowe oraz które biblioteki należy połączyć z plikiem obiektu.

Uruchamianie skompilowanego programu odbywa się przez następującą komendę:

```
mpirun -np <liczba_procesów> <nazwa_pliku_wynikowego> <parametry>
```

W wyżej wymienionej komendzie `|liczba_procesów|` jest liczbą całkowitą dodatnią i wskazuje, ile procesów ma być wykonanych równolegle. `|nazwa_pliku_wynikowego|` oraz `|parametry|` przekazywane są do procesów za pośrednictwem zmiennych `argc` i `argv` znajdujących się w nagłówku funkcji `main` (zgodnie z zasadami języka C).

2.4 Inicjalizacja i kończenie programu

Większość elementów składowych programu napisanego przy użyciu MPI jest instrukcjami natywnymi używanego języka (C, C++, Ada, Fortran). Aby umożliwić korzystanie z instrukcji nowej biblioteki, należy dodać następującą instrukcję (w języku C):

```
include "mpi.h"
```

Spowoduje to włączenie pliku nagłówkowego `mpi.h`. Znajdują się w nim prototypy funkcji MPI, makrodefinicje, definicje typów oraz inne definicje i deklaracje potrzebne do skompilowania programu MPI. Pierwszą instrukcją, jaka jest wykonywana przed rozdzieleniem pracy pomiędzy wątki jest `MPI_INIT` o następującej składni:

```
int MPI_Init(  
    int* argc_p  
    char*** argv_p)
```

Argumenty funkcji są wskaźnikami do argumentów funkcji `main`, kolejno `argc` i `argv`. W przypadku, gdy parametry wywołania nie istnieją lub nie są potrzebne dla instrukcji MPI, można do obu przekazać wartość `NULL`. Wartością zwracaną przez `MPI_Init` jest kod błędu, co jest standardem dla większości funkcji tej biblioteki. Jeżeli zwrócona wartość jest równa `MPI_SUCCESS`, oznacza to poprawne wykonanie inicjalizacji. Pozostałe kody oznaczają błędy jakie wystąpiły podczas pracy, a ich wartości uzależnione są od implementacji biblioteki. Informację o tym, czy w danym momencie programu mechanizm MPI został zainicjalizowany, możemy uzyskać za pomocą funkcji `MPI_Initialized`. Rzadziej używaną alternatywę dla `MPI_Init` stanowi `MPI_Init_thread`, który dodatkowo inicjalizuje środowisko wątków.

Analogicznie, ostatnią instrukcją, jaka powinna zostać wywołana w programie MPI, jest funkcja finalizacji:

```
int MPI_Finalize(void);
```

Jej wywołanie powoduje zwolnienie wszystkich zasobów komputera, które zostały wcześniej zaalokowane przez funkcję inicjalizacji, a następnie wykorzystywane w trakcie obliczeń równoległych. Podobnie jak wcześniejsza funkcja, `MPI_Finalize` zwraca kod błędu.

Nieobowiązkowymi, ale niemal równie ważnymi funkcjami są `MPI_Comm_size` oraz `MPI_Comm_rank` o następującej składni:

```
int MPI_Comm_size(  
    MPI_Comm comm,  
    int* comm_size_p);
```

```
int MPI_Comm_rank(  
    MPI_Comm comm,  
    int* my_rank_p);
```

W obu przypadkach, pierwszym argumentem jest komunikator, w którym znajduje się proces go wywołujący. Komunikatory w bibliotece MPI są nieprzeźroczystym obiektem (tzn. o nieznanym wewnętrznej strukturze), w ramach której kolekcja procesów może wymieniać między sobą dane. Posiadają one własny typ, `MPI_Comm`. `MPI_Comm_size` jako swój drugi argument zwraca liczbę procesów znajdującą się w komunikatorze, natomiast `MPI_Comm_rank` informuje jaki identyfikator został przydzielony procesowi który wykonał tę funkcję w ramach komunikatora. Funkcje te ułatwiają rozdzielanie zadań pomiędzy procesy oraz kontrolę nad przepływem pracy algorytmu równoległego.

2.5 Typy danych w MPI

Interfejs MPI wykorzystuje własne typy danych w trakcie wymiany informacji. Zamiast informacji o ilości przesyłanych bajtów, w trakcie transferu wysyłana jest informacja o ilości przesyłanych elementów danego typu (argument `count`). Wartość ta może być równa zero, co jest tożsame z informacją, że część wiadomości zawierająca dane jest pusta. Podstawowe typy danych MPI, których można użyć w trakcie

komunikacji odpowiadają typom podstawowym języka programowania, z którego korzystamy i różnią się w zależności od implementacji.

Typ MPI	Odpowiednik w języku C
MPI_CHAR	char
MPI_SHORT	signed short int
MPI_INT	signed int
MPI_LONG	signed long int
MPI_LONG_LONG_INT	signed long long int
MPI_SIGNED_CHAR	signed char
MPI_UNSIGNED_CHAR	unsigned char
MPI_UNSIGNED	unsigned short int
MPI_UNSIGNED_LONG	unsigned long int
MPI_FLOAT	float
MPI_DOUBLE	double
MPI_LONG_DOUBLE	long double
MPI_C_BOOL	_Bool
MPI_BYTE	8 bitów (8 cyfr binarnych)
MPI_PACKED	-

Rysunek 3: Najważniejsze typy MPI i ich odpowiedniki dla języka C Źródło: [2], str 26

3 Komunikacja między procesami w bibliotece MPI

3.1 Komunikacja punkt-punkt

3.2 Komunikacja rozgłoszeniowa

3.3 Redukcja danych

3.4 Dodatkowe funkcje

4 Podsumowanie

Literatura

- [1] Z. J. Czech, *Wprowadzenie do obliczeń równoległych*, Wydawnictwo PWN, Warszawa 2013, wyd. 2
- [2] Message Passing Interface Forum, *MPI: A Message-Passing Interface Standard, Version 3.0*, High Performance Computing Center Stuttgart (HLRS), Stuttgart 2012
- [3] P. Pacheco, *An Introduction to Parallel Programming*, Morgan Kaufmann, San Francisco 2001
- [4] M. J. Quinn, *Parallel Programming in C with MPI and OpenMP*, McGraw-Hill, Nowy Jork 2003